

# 《深度学习》Final Project 任务说明

## 利用 LLM 完成现实任务并进行系统评测

### 1 项目背景

随着大语言模型 (Large Language Models, LLMs) 的快速发展, LLM 已经被广泛应用于学习辅助、文本写作、代码生成、信息整理、生活决策等现实任务中。然而, 不同 LLM 在具体任务中的表现存在明显差异。例如, 有的模型更擅长中文写作, 有的模型更擅长代码生成, 有的模型在推理任务中表现更稳定, 也有一些模型容易产生幻觉或给出不可靠的信息。

本课程的 Final Project 要求同学们选择一个现实生活中的具体任务, 利用 LLM 辅助完成该任务, 并系统比较多种 LLM 在该任务上的能力表现。项目重点不是简单体验 LLM, 而是希望同学们能够从任务定义、测试样例构造、Prompt 设计、评价指标、实验结果分析和失败案例分析等角度, 理解当前 LLM 的能力边界。

### 2 项目目标

本项目要求同学们完成以下目标:

1. 选择一个具有现实意义的任务;
2. 使用至少 5 种不同的 LLM 完成该任务;
3. 构造一组测试样例, 对不同模型进行统一测试;
4. 设计合理的 Prompt, 并分析 Prompt 对模型表现的影响;
5. 设计评价指标, 对不同模型的输出进行系统比较;
6. 分析不同模型的优势、缺陷、适用场景和失败模式;
7. 总结 LLM 在该任务中的实际价值和局限性。

### 3 小组要求

本项目为小组 Project。每个小组人数为 1–5 人。

每个小组需要独立完成任务选题、实验设计、模型测试、结果分析和项目报告撰写。小组人数可以根据任务复杂度和实际情况自行确定。人数较多的小组应承担更充分的测试样例设计、更多的案例分析和更系统的实验比较。

### 4 基本任务要求

每个小组需要完成以下内容：

1. 选择一个现实生活中的具体任务；
2. 至少选择 5 种不同的 LLM 进行比较；
3. 为任务构造一组测试样例；
4. 对所有模型使用尽可能统一的测试输入和实验流程；
5. 设计基础 Prompt 和改进 Prompt；
6. 对不同 LLM 的输出进行定量和定性分析；
7. 总结不同模型在该任务上的能力差异。

可选模型包括但不限于 ChatGPT / GPT 系列、Claude、Gemini、DeepSeek、Qwen、Kimi、GLM、文心一言等。报告中必须写清楚具体模型名称、版本或使用平台，并记录实际使用日期。

### 5 任务选题建议

任务必须是真实、有明确目标、可以评价结果质量的任务。可以从以下方向中选择，也可以自行设计。

#### 5.1 学习辅助类

例如：

- 让 LLM 帮助复习一门课程；
- 根据教材内容生成习题和答案；
- 解释一个复杂概念；
- 帮助完成英文论文阅读；

- 根据课堂笔记生成复习提纲；
- 让 LLM 扮演助教，回答学生的学习问题。

评价重点可以包括：准确性、解释清晰度、知识覆盖度、是否存在幻觉、是否适合本科生理解。

## 5.2 写作与表达类

例如：

- 修改英文邮件；
- 润色中文或英文短文；
- 生成个人陈述初稿；
- 修改简历；
- 帮助撰写课程总结；
- 将口语化表达改写为正式表达。

评价重点可以包括：语言流畅性、逻辑结构、表达准确性、是否符合目标场景、是否过度夸张。

## 5.3 信息整理类

例如：

- 对多篇材料进行摘要；
- 整理某个技术主题的发展脉络；
- 对比多个产品、学校、岗位或技术方案；
- 从长文本中提取关键信息；
- 根据材料生成结构化表格。

评价重点可以包括：信息完整性、结构清晰度、事实准确性、是否遗漏关键信息、是否能够区分重要信息和次要信息。

## 5.4 代码辅助类

例如：

- 让 LLM 生成 Python 数据处理代码；

- 调试一段有错误的程序；
- 解释深度学习代码；
- 根据需求实现一个小工具；
- 比较不同模型的代码生成能力；
- 让 LLM 帮助理解 PyTorch、NumPy 或 Scikit-learn 代码。

评价重点可以包括：代码正确性、可运行性、鲁棒性、注释质量、是否引入不必要复杂度。

## 5.5 生活决策类

例如：

- 制定健身计划；
- 制定旅行计划；
- 制定学习计划；
- 规划时间管理方案；
- 帮助分析某个消费决策；
- 帮助制定求职、考研或科研计划。

评价重点可以包括：可执行性、个性化程度、逻辑合理性、约束满足情况、风险提示是否充分。

# 6 实验设计要求

每个小组至少需要构造 10–20 个测试样例。测试样例应覆盖任务中的不同难度、不同输入形式和不同情形。

例如，如果任务是“让 LLM 帮助学生学习深度学习概念”，测试样例可以设计如下：

| 样例编号 | 输入问题                                  | 难度 | 期望能力 |
|------|---------------------------------------|----|------|
| 1    | 请解释过拟合和欠拟合的区别。                        | 简单 | 概念解释 |
| 2    | 为什么 Batch Normalization 可以加速训练?       | 中等 | 机制理解 |
| 3    | 请比较 CNN、RNN 和 Transformer 的适用场景。      | 中等 | 对比分析 |
| 4    | 请解释 Attention 公式中的 Query、Key 和 Value。 | 中等 | 数学解释 |
| 5    | 请指出一段 PyTorch 代码中的错误。                 | 较难 | 代码调试 |

每个模型应在相同测试样例上进行测试，尽量保证 Prompt、输入内容和实验条件一致。

7 Prompt 设计要求

每个小组至少需要设计两类 Prompt。

7.1 基础 Prompt

基础 Prompt 用于公平比较不同模型的基本能力。所有模型应尽量使用相同的输入。例如：

你是一名深度学习课程助教。请用本科生能够理解的方式解释以下概念，并给出一个简单例子：

[具体问题]

7.2 改进 Prompt

改进 Prompt 应在基础 Prompt 的基础上加入更明确的角色、输出格式、约束条件或评价标准。例如：

你是一名深度学习课程助教。请按照以下格式回答问题：

- 1. 核心定义；
- 2. 直观解释；
- 3. 数学表达；

4. 简单例子；

5. 常见误区。

要求：

- 面向本科生；
- 避免过度复杂的术语；
- 如果涉及公式，请解释每个符号的含义。

问题：

[具体问题]

学生需要分析：改进 Prompt 是否提升了模型表现？哪些模型对 Prompt 更敏感？哪些模型即使使用简单 Prompt 也能给出高质量回答？

## 8 评价指标设计

每个小组需要根据具体任务设计清晰的评价指标。建议采用 1-5 分制，也可以根据任务特点设计其他评价方式。

可参考以下指标：

| 指标    | 含义                  |
|-------|---------------------|
| 正确性   | 回答是否事实正确，是否存在明显错误。  |
| 完整性   | 是否覆盖任务所需的关键信息。      |
| 清晰度   | 表达是否易懂，结构是否清楚。      |
| 可执行性  | 输出是否能够真正用于解决现实任务。   |
| 可靠性   | 是否存在幻觉、编造、过度自信等问题。  |
| 个性化程度 | 是否能够根据具体需求调整回答。     |
| 效率    | 回答是否简洁，是否需要多轮修改。    |
| 安全性   | 是否避免隐私泄露、错误建议或不当内容。 |

建议最终给出如下汇总表：

| 模型    | 正确性 | 完整性 | 清晰度 | 可执行性 | 可靠性 | 总体评价 |
|-------|-----|-----|-----|------|-----|------|
| LLM-1 |     |     |     |      |     |      |
| LLM-2 |     |     |     |      |     |      |
| LLM-3 |     |     |     |      |     |      |
| LLM-4 |     |     |     |      |     |      |
| LLM-5 |     |     |     |      |     |      |

## 9 结果分析要求

项目报告不能只给出表格分数，必须对模型差异进行分析。至少需要回答以下问题：

1. 哪个模型整体表现最好？为什么？
2. 哪个模型在该任务中最稳定？
3. 哪些模型容易出现幻觉或错误？
4. 哪些模型更擅长中文？哪些更擅长英文？
5. 哪些模型更适合代码、推理、写作、总结或计划类任务？
6. 改进 Prompt 后，哪些模型提升明显？
7. 该任务中 LLM 是否真正有用？其局限性是什么？
8. 如果在现实生活中使用 LLM 完成该任务，还需要人工检查哪些内容？

## 10 典型案例与失败案例分析

每个小组需要在报告中展示若干典型案例，包括：

- 表现最好的模型输出案例；
- 表现较差的模型输出案例；
- 不同模型回答差异明显的案例；
- 模型产生幻觉、错误、遗漏或不合理建议的案例；
- Prompt 改进前后模型输出变化明显的案例。

对于每个案例，不能只粘贴模型回答，还需要进行分析。例如：

- 模型为什么回答得好？
- 模型错误出现在什么地方？
- 错误是否具有隐蔽性？
- 人类用户是否容易发现该错误？
- 该错误会不会影响任务的实际完成？

## 11 提交材料

每个小组需要提交以下材料：

1. 项目报告 PDF；
2. 实验原始记录，包括 Prompt、输入样例和模型输出；
3. 结果表格，建议使用 Excel、CSV 或 Markdown 表格；
4. 如涉及代码任务，需要提交代码文件；
5. 如使用 GitHub，需要提交 GitHub 链接。

报告建议结构如下：

1. 项目背景与任务说明；
2. 小组成员与分工；
3. 所选 LLM 及使用方式；
4. 测试样例设计；
5. Prompt 设计；
6. 评价指标；
7. 实验结果；
8. 定量分析；
9. 典型案例分析；
10. 失败案例分析；
11. 结论与反思。

## 12 注意事项

1. 不允许只提交与 LLM 的聊天截图，必须有系统的实验设计和结果分析。
2. 不允许只测试一个问题，必须构造一组测试样例。
3. 不允许只给主观感受，必须给出评价指标和结果表格。
4. 不建议上传个人隐私数据、身份证件、银行卡、真实病历等敏感信息。
5. 若使用 LLM 辅助完成报告写作，必须说明哪些部分由 LLM 辅助完成。

6. 模型输出可能存在幻觉，学生需要进行人工核查，而不是直接相信模型回答。
7. 所有小组应保证实验记录真实、完整、可追溯。

## 13 项目题目示例

学生可以参考以下题目，也可以自行设计题目：

1. 不同 LLM 在深度学习概念解释任务中的能力比较；
2. 不同 LLM 在 Python 代码调试任务中的表现评测；
3. 不同 LLM 在英文邮件润色任务中的能力分析；
4. 不同 LLM 在论文摘要与信息提取任务中的比较；
5. 不同 LLM 在旅行计划制定任务中的可靠性分析；
6. 不同 LLM 在简历修改任务中的实用性评测；
7. 不同 LLM 在课程复习资料生成任务中的能力比较；
8. 不同 LLM 在数学推理题解答中的错误模式分析；
9. 不同 LLM 在中文写作润色任务中的表现比较；
10. 不同 LLM 在生活决策建议任务中的可执行性评测；
11. 不同 LLM 在科研论文阅读辅助任务中的能力比较；
12. 不同 LLM 在表格信息提取与总结任务中的表现评测。

## 14 项目核心要求总结

本项目的核心要求可以概括为：

选择一个真实任务，构造测试样例，使用至少 5 种 LLM 完成任务，设计评价指标，系统比较模型表现，并分析其优势、缺陷与适用场景。