

Final Project 报告

不同 LLM 在多任务场景下的能力比较研究

一、 基本信息

项目	内容
课程名称	深度学习
Project 主题	利用 LLM 完成现实任务并进行系统评测
项目名称	不同 LLM 在代码调试、学习辅助与写作表达任务中的能力比较
小组成员	刘承龙, 韩玉轩, 潘旭

二、 项目概述

本项目围绕课程 Final Project 的要求展开，目标是在真实任务场景中比较不同大语言模型的能力表现，而不是停留在主观体验层面。我们将任务拆分为代码辅助、学习辅助和写作表达三类：代码辅助关注模型是否能够定位并修复 Python 程序错误；学习辅助关注模型能否面向本科生解释深度学习概念；写作表达关注模型能否在保留原意的前提下提升文本的正式度、逻辑性和场景适配度。

实验设计遵循“统一样例、双 Prompt、定量评分、定性分析”的流程。三个任务共整理 35 个测试样例，其中代码调试 15 个、学习辅助 10 个、写作表达 10 个。每个任务均设置基础 Prompt 与改进 Prompt，并对至少 5 种模型输出进行记录和评分。这样的设计既能比较模型的基础能力，也能观察结构化 Prompt 对输出质量的提升效果。

从整体结果看，GPT 系列在三类任务中表现最稳定，Claude 在代码调试任务中结构化解释能力突出，DeepSeek 在中文技术类任务中表现较强，Qwen 对改进 Prompt 的响应较明显，Gemini 虽然基础表现相对弱，但在明确格式和约束后仍有较大提升空间。

三、项目目标与任务要求对应

根据 Final_project.pdf，项目需要覆盖任务定义、测试样例构造、Prompt 设计、评价指标、实验结果分析和失败案例分析等环节。下表概括课程要求与本项目完成情况，后续章节将分别展开说明。

课程要求	本项目完成情况
选择现实任务	选择代码调试、深度学习概念解释、写作表达三类高频现实任务。
至少 5 种 LLM	每类任务均覆盖至少 5 个模型或输出组。
构造测试样例	代码 15 个，学习 10 个，写作 10 个，覆盖不同难度与输入形式。
设计 Prompt	每类任务均包含基础 Prompt 与改进 Prompt。
评价与分析	使用 1-5 分制评分，并结合典型案例和失败案例分析模型差异。
提交材料	保留 Prompt、模型输出、评分表、代码样例、最终 DOCX/PDF 报告与查漏清单。

四、小组成员与分工

韩玉轩负责代码辅助部分；刘承龙负责学习辅助类、写作表达类两个任务的记录与最终整理；潘旭负责打分工作和初步报告。

成员	分工职责
韩玉轩	负责 Python 代码调试样例、Prompt、模型输出和代码任务评分材料。
刘承龙	负责学习辅助和写作表达任务记录整理，并完成最终报告重构、材料规整和提交前检查。
潘旭	负责评分工作和初步报告，为最终分析提供评分表与基础文字。

五、实验环境与材料组织

5.1 材料目录结构

当前仓库按照任务类别组织材料。代码辅助类目录保留测试代码、Prompt、原始输出和评分结果；学习辅助类目录保留模型输出、使用记录和补齐后的评分文件；写作表达类目录保留 Prompt、模型输出和评分报告。本报告不逐一粘贴所有原始输出，而是在正文中说明目录结构和关键结果，完整记录仍保留在对应文件夹中，便于复核。

项目	内容
1_代码辅助类	代码调试样例、基础/改进 Prompt、模型输出、评分结果、15 个错误样例。
2_学习辅助类	深度学习概念解释 Prompt、五组模型输出、记录文件、evaluation_scores.md。
3_写作表达类	写作表达 Prompt、五组模型输出、记录文件、evaluation_scores.md。

5.2 所选模型与使用方式

代码任务使用 GPT-4o、Claude 3.5 Sonnet、Gemini 2.0 Flash、Qwen2.5-72B 和 DeepSeek-V3；学习与写作任务使用 DeepSeek-V4 Flash、GPT-5.5 Instant、Gemini-3.5 Flash、Kimi-2.6 Flash 和 Qwen-3.7。部分记录文件仅保留模型名称与使用日期，平台字段未单独列出，因此本报告在对应位置作了说明。

任务	模型组	记录日期	说明
代码辅助	GPT-4o、Claude 3.5 Sonnet、Gemini 2.0 Flash、Qwen2.5-72B、DeepSeek-V3	2026-06-28 至 2026-06-30	平台与版本见 README 和 experiment_metadata。
学习辅助	DeepSeek-V4 Flash、GPT-5.5 Instant、Gemini-3.5 Flash、Kimi-2.6 Flash、Qwen-3.7	2026-07-03	记录文件标注模型名称和日期，平台均为网页版。
写作表达	DeepSeek-V4 Flash、GPT-5.5 Instant、Gemini-3.5 Flash、Kimi-2.6 Flash、Qwen-3.7	2026-07-01	记录文件标注模型名称和日期，平台均为网页版。

六、测试样例设计

测试样例的设计重点是覆盖不同难度、不同输入形式和不同能力要求。代码任务并不只测试语法错误，还包括运行时错误、逻辑错误和性能问题；学习任务覆盖概念解释、机制理解、数学解释、代码调试和论文阅读辅助；写作任务覆盖职场、校园、商务、学术和科普等多种表达场景。

任务	样例数量	覆盖范围	设计意图
代码辅助	15	语法错误、运行时错误、逻辑错误、性能问题	检验模型能否定位错误根因，并给出可运行且不过度重构的修复方案。
学习辅助	10	概念解释、机制理解、对比分析、数学解释、代码调试、论文阅读	检验模型能否面向本科生提供准确、完整、清晰的学习辅助。
写作表达	10	请假申请、英文消息、校园通知、简历项目、学术段落、商务文案等	检验模型能否在保留原意的基础上改善语言和场景适配度。

这种样例设计使实验既能看到模型在基础任务上的表现，也能暴露较隐蔽的问题。例如代码任务中的闰年判断和 off-by-one 错误，表面上并不明显；学习任务中的 Batch Normalization 和 Softmax 公式解释，容易出现“说法正确但语境不完整”的问题；写作任务中的简历润色和产品文案，则容易诱发模型补充原文没有提供的信息。

七、Prompt 设计

本项目采用基础 Prompt 与改进 Prompt 的双轨设计。基础 Prompt 只给出最小任务要求，主要用于观察模型在较少约束下的原始能力；改进 Prompt 在基础要求上加入角色设定、输出结构、约束条件和评价标准，用于观察 Prompt 工程是否能稳定提升输出质量。

任务	基础 Prompt 特点	改进 Prompt 特点
代码辅助	直接要求找出 Python 代码错误并给出修正代码。	要求按错误类型、错误定位、错误原因、修复方案、验证说明和注意事项输出。
学习辅助	要求用本科生能理解的方式解释概念并举例。	要求给出核心定义、直观解释、技术说明、简单例子和常见误区。
写作表达	要求润色文本、保留原意并提升正式度。	强调角色、目标场景、格式约束和“不得新增原文不存在的信息”。

从结果看，改进 Prompt 的价值主要体现在三个方面：第一，它能使回答结构更稳定，减少遗漏；第二，它能迫使模型解释原因而不只是给出结论；第三，它能在写作任务中降低过度发挥和新增信息的风险。不过，Prompt 改进并不能完全消除模型幻觉，因此后续案例分析仍重点讨论人工复核的必要性。

八、评价指标

评价指标根据任务特点分别设计，但整体采用 1-5 分制，便于跨模型和跨 Prompt 比较。代码任务强调正确性和可运行性，学习任务强调知识准确与解释完整，写作任务强调语言质量和原意保留。

任务	评价指标	关注重点
代码辅助	正确性、可运行性、鲁棒性、注释质量、简洁性	是否找到根因、修复后能否运行、是否考虑边界条件。
学习辅助	正确性、完整性、清晰度、可靠性、知识覆盖度	是否事实正确、解释充分、适合本科生理解。
写作表达	语言流畅性、逻辑结构、表达准确性、场景符合度、克制度	是否自然得体、保留原意、避免新增信息和夸张表达。

九、实验结果与分析

9.1 代码辅助类结果

代码辅助类中，基础 Prompt 下 DeepSeek-V3、Claude 3.5 Sonnet 和 GPT-4o 的均分较为接近，说明这些模型对常见 Python 错误具有较强的基础识别能力。改进 Prompt 后，Claude 3.5 Sonnet 的均分达到 4.88，GPT-4o 达到 4.80，DeepSeek-V3 达到 4.77，整体差距进一步缩小。

模型	正确性	可运行性	鲁棒性	注释质量	简洁性	均分/5
Claude 3.5 Sonnet	5.00	5.00	4.80	4.87	4.73	4.88
GPT-4o	4.93	5.00	4.73	4.67	4.67	4.80
DeepSeek-V3	4.93	4.93	4.67	4.60	4.73	4.77
Qwen2.5-72B	4.87	4.93	4.60	4.53	4.60	4.71
Gemini 2.0 Flash	4.80	4.93	4.53	4.40	4.67	4.67

从维度上看，改进 Prompt 对“注释质量”和“鲁棒性”的提升最明显。基础 Prompt 往往能指出语法错误或运行时错误，但对边界条件、验证方式和修复理由说明不足；改进 Prompt 要求模型显式说明错误定位和验证过程，因此更适合作为真实代码调试辅助。需要注意的是，逻辑错误仍是代码任务中的难点，尤其是闰年判断、差一错误和阶乘初始值等问题，模型有时会给出看似合理但不完整的修复。

9.2 学习辅助类结果

学习辅助类中，GPT-5.5 Instant 在基础 Prompt 下均分为 4.66，改进 Prompt 后提升到 4.92，表现最稳定。DeepSeek-V4 Flash 和 Qwen-3.7 在改进 Prompt 下分别达到 4.76 和 4.72，也能提供较完整的概念解释。Gemini-3.5 Flash 虽然基础得分最低，但改进后从 4.16 提升到 4.48，说明结构化提示能弥补部分表达和覆盖不足。

模型	正确性	完整性	清晰度	可靠性	知识覆盖度	均分/5
GPT-5.5 Instant	5.00	4.90	4.90	5.00	4.80	4.92
DeepSeek-V4 Flash	4.90	4.70	4.70	4.90	4.60	4.76
Qwen-3.7	4.80	4.70	4.70	4.80	4.60	4.72
Kimi-2.6 Flash	4.80	4.60	4.60	4.80	4.50	4.66
Gemini-3.5 Flash	4.70	4.40	4.40	4.60	4.30	4.48

学习任务暴露出的主要问题不是完全错误，而是“浅层正确”。例如模型可能知道 Batch Normalization 能加速训练，也能列出若干优点，但没有解释均值方差标准化、可学习参数 γ/β 、训练与推理阶段统计量差异等关键机制。对于本科生学习而言，这类回答容易造成“会背结论但不理解原理”的问题，因此学习辅助类输出必须关注知识语境和解释深度。

9.3 写作表达类结果

写作表达类中，GPT-5.5 Instant 在改进 Prompt 下达到 5.00，是三类任务中表现最突出的单项结果。Qwen-3.7 从基础 Prompt 的 4.08 提升到改进 Prompt 的 4.74，提升幅度明显，说明写作表达任务对格式约束和场景说明较为敏感。Kimi-2.6 Flash、DeepSeek-V4 Flash 和 Gemini-3.5 Flash 在语言流畅性方面普遍不差，但在表达准确性和克制度方面存在差异。

实际模型	语言	逻辑	准确	场景	克制	均分/5
GPT-5.5 Instant	5.00	5.00	5.00	5.00	5.00	5.00
Qwen-3.7	4.90	4.80	4.40	4.60	5.00	4.74
Kimi-2.6 Flash	5.00	4.90	4.10	4.60	4.30	4.58
DeepSeek-V4 Flash	4.90	4.90	3.60	4.50	4.20	4.42
Gemini-3.5 Flash	4.70	4.50	3.60	4.30	4.20	4.26

写作任务的核心风险是模型“写得更好看”但不一定“更真实”。在简历项目经历、产品说明文案和商务表达中，模型容易补充技术栈、数据结果或承诺性表述。此类信息如果未经用户确认，就会从润色变成事实编造。因此，写作表达类任务中最重要的人工复核点不是语法，而是每一处新增信息是否有来源。

9.4 综合定量分析

综合改进 Prompt 下的结果，GPT 系列在学习和写作任务中都处于第一梯队，Claude 在代码任务中表现突出，DeepSeek 在中文技术类任务中有竞争力，Qwen 的可塑性较强，Gemini 对 Prompt 优化敏感但基础能力仍相对弱。由于不同子任务使用的具体模型版本并不完全一致，综合排名主要用于观察趋势，不应视为严格的统计结论。

排名	模型	代码辅助	学习辅助	写作表达	平均分	稳定性
1	GPT-4o / GPT-5.5 Instant	4.80	4.92	5.00	4.91	★★★★★
2	Claude 3.5 Sonnet	4.88	—	—	4.88	★★★★★
3	Qwen-3.7	4.71	4.72	4.74	4.72	★★★★☆
4	DeepSeek-V3 / V4 Flash	4.77	4.76	4.42	4.65	★★★★☆
5	Kimi-2.6 Flash	—	4.66	4.58	4.62	★★★★☆
6	Gemini 2.0 / 3.5 Flash	4.67	4.48	4.26	4.47	★★★☆☆

从任务类型看，LLM 在语言流畅性和结构化表达上普遍表现较好，在代码语法错误和常见运行时错误上也较可靠；但在逻辑规则、边界条件、公式语境和事实约束方面仍容易出问题。这说明当前 LLM 更适合承担“初稿生成、解释辅助、候选方案提供”的角色，而不适合在没有人工复核的情况下直接作为最终判断依据。

十、 典型案例分析

10.1 优秀案例：写作样例 10 的科普风格改写

在写作样例 10 中，原始文本是较口语化的中文表达，要求改写为正式科普风格。GPT-5.5 Instant 在改进 Prompt 下完整保留了原文的四个核心信息：人工智能能够写作和绘图、公众担心就业、AI 更多是辅助工具、用户应主动学习使用工具。

模型输出节选：人工智能技术近年来发展迅速，已能够完成文本生成、图像创作等复杂任务。这一进展引发了一些关于就业前景的担忧。然而，现有技术条件下，AI 更多地扮演辅助工具的角色，旨在提升人类工作效率，而非完全替代人类劳动力。

这个案例表现好的原因在于模型没有把润色理解为扩写，而是准确完成了风格转换。它使用“现有技术条件下”“更多地扮演”等限定性表达，既增强了正式度，也避免了过度绝对化。对于现实写作任务而言，这种克制性比华丽辞藻更重要。

10.2 优秀案例：Attention 中 Q/K/V 的解释

学习辅助类中，表现较好的回答通常具有从直观到抽象的递进结构。以 Attention 中 Query、Key、Value 的解释为例，高质量回答会先使用图书馆检索或信息匹配的类比建立直觉，再给出缩放点积注意力公式，最后解释 softmax、缩放因子和加权求和的作用。

这种回答方式适合本科生理解，因为它既避免一上来堆砌公式，也没有停留在生活化比喻层面。相比之下，较弱的回答往往只说“Q 是查询，K 是键，V 是值”，没有解释三者如何共同决定注意力权重，也没有说明 self-attention 和 cross-attention 中 Q/K/V 来源的差异。

十一、失败案例分析

11.1 浅层解释：Batch Normalization

Gemini-3.5 Flash 在基础 Prompt 下解释 Batch Normalization 时，能够列出“加速训练”“缓解梯度问题”“提高稳定性”等常见结论，但缺少数学操作和训练/推理阶段差异。这个回答不是完全错误，却不适合作为深入学习材料。

该问题的隐蔽性在于：初学者很容易被流畅的表述说服，以为自己已经理解了 BN。实际上，如果不能说明均值、方差、标准化、gamma/beta 以及推理阶段移动平均统计量，就无法真正判断 BN 为什么有效、什么时候可能失效。

11.2 事实新增：写作润色中的信息扩展

写作表达任务中，部分模型在简历或产品文案润色时会新增原文没有提供的信息。例如，原文只说“用 Python 做了学生管理系统”，模型可能补充 Tkinter、SQLite 或具体性能结果。这些补充在文本上看似合理，却可能与事实不符。

因此，写作任务的失败模式并不一定表现为语言不通顺，反而常常表现为“语言太顺、细节太完整”。这类错误在人类阅读时更难发现，因为新增信息增强了文本可信度，却降低了事实可靠性。

十二、失败模式总结

失败模式	代码辅助	学习辅助	写作表达	隐蔽性	可检测性
逻辑规则遗漏	★★★	★★	★	极高	低
新增未提供信息	★	★★	★★★	高	中
过度自信/极致化表述	★	★★	★★★	中	中
浅层解释/缺乏深度	★★	★★★	★	中	高
公式语境不完整	—	★★★	—	极高	低
边界条件考虑不足	★★★	—	—	高	中

综合三类任务，可以将失败模式概括为三类：第一，逻辑规则遗漏，例如闰年判断只考虑能否被 4 整除；第二，语境限定不足，例如把 Softmax 与交叉熵组合后的梯度简化为一般交叉熵梯度；第三，事实边界松动，例如写作润色时新增原文未提供的信息。

这些失败模式说明，LLM 的主要风险并不总是“明显答错”，而是“看起来合理但缺少关键限定”。因此，在现实使用中应把模型输出视为高质量初稿，而不是最终答案。尤其是在代码、学习和正式写作中，用户必须保留验证、查证和判断的责任。

十三、结论与反思

本项目通过三类真实任务比较了多种 LLM 的输出质量。实验表明，当前主流 LLM 已经能够在代码调试、学习解释和写作润色中提供较高价值，尤其适合用于生成初稿、整理结构、解释常见概念和提供修改建议。改进 Prompt 能显著提升输出结构和完整性，是实际使用中非常重要的技巧。

但是，实验也表明 LLM 的能力边界仍然明显。代码任务中，模型可能忽略边界条件或业务规则；学习任务中，模型可能给出“正确但不完整”的解释；写作任务中，模型可能为了让文本更专业而新增事实。Prompt 可以降低这些问题发生的概率，但不能完全消除风险。

因此，最合理的使用方式是“LLM 生成 + 人工复核”。在代码场景中，应运行测试并检查边界条件；在学习场景中，应结合教材、课件或权威资料核对公式和概念；在写作场景中，应逐句确认模型是否改变原意或新增事实。只有在这种协作流程下，LLM 的效率优势才能真正转化为可靠的实际价值。

十四、LLM 辅助写作说明

本报告在结构整理、语言润色、表格生成中使用了 LLM 辅助；但测试样例、模型输出记录、评分表和核心分析结论均来自小组已有原始材料与人工整理。